

Министерство образования Республики Беларусь
Учреждение образования
"Брестский государственный технический университет"
Кафедра ИИТ

Лабораторная работа №1

По дисциплине "Обработка изображений в интеллектуальных системах"

Тема: «Обучение классификаторов средствами библиотеки PyTorch»

Выполнил:

Студент 4 курса

Группы ИИ-24

Бузель С.Д.

Проверил:

Андренко К. В.

Брест 2025

Цель: научиться конструировать нейросетевые классификаторы и выполнять их обучение на известных выборках компьютерного зрения.

Задание:

1. Выполнить конструирование своей модели СНС, обучить ее на выборке по заданию (использовать `torchvision.datasets`). Предпочтение отдавать как можно более простым архитектурам, базирующимся на базовых типах слоев (сверточный, полносвязный, подвыборочный, слой нелинейного преобразования). Оценить эффективность обучения на тестовой выборке, построить график изменения ошибки (`matplotlib`);
 2. Ознакомьтесь с state-of-the-art результатами для предлагаемых выборок (из материалов в сети Интернет). Сделать выводы о результатах обучения СНС из п. 1;
 3. Реализовать визуализацию работы СНС из пункта 1 (выбор и подачу на архитектуру произвольного изображения с выводом результата);
 4. Оформить отчет по выполненной работе, загрузить исходный код и отчет в соответствующий репозиторий на `github`.

№ варианта	Выборка	Размер исходного изображения	Оптимизатор
3	CIFAR-10	32X32	SGD

Код программы:

```

# Классы изображений
classes = ('plane', 'car', 'bird', 'cat',
           'deer', 'dog', 'frog', 'horse', 'ship', 'truck')

# --- Шаг 2: Определение архитектуры сверточной нейронной сети ---
class SimpleCNN(nn.Module):
    def __init__(self):
        super(SimpleCNN, self).__init__()
        # Первый сверточный слой: 3 входных канала (RGB), 6 выходных, ядро 5x5
        self.conv1 = nn.Conv2d(3, 6, 5)
        # Слой подвыборки (max pooling) с окном 2x2
        self.pool = nn.MaxPool2d(2, 2)
        # Второй сверточный слой
        self.conv2 = nn.Conv2d(6, 16, 5)
        # Полносвязные слои
        self.fc1 = nn.Linear(16 * 5 * 5, 120) # 16*5*5 - размерность после conv2 и pool
        self.fc2 = nn.Linear(120, 84)
        self.fc3 = nn.Linear(84, 10) # 10 - количество классов

    def forward(self, x):
        # Применение слоев с функцией активации ReLU
        x = self.pool(F.relu(self.conv1(x)))
        x = self.pool(F.relu(self.conv2(x)))
        # Выравнивание данных для полносвязного слоя
        x = x.view(-1, 16 * 5 * 5)
        x = F.relu(self.fc1(x))
        x = F.relu(self.fc2(x))
        x = self.fc3(x)
        return x

net = SimpleCNN()

# --- Шаг 3: Определение функции потерь и оптимизатора ---
criterion = nn.CrossEntropyLoss()
optimizer = optim.SGD(net.parameters(), lr=0.001, momentum=0.9)

# --- Шаг 4: Обучение нейронной сети ---
loss_history = []
epochs = 5 # Для демонстрации, можно увеличить для лучшей точности

for epoch in range(epochs):
    running_loss = 0.0
    for i, data in enumerate(trainloader, 0):
        # Получение входных данных. data - список [inputs, labels]
        inputs, labels = data

        # Обнуление градиентов
        optimizer.zero_grad()

        # Прямое распространение и обратное распространение и оптимизация
        outputs = net(inputs)
        loss = criterion(outputs, labels)
        loss.backward()
        optimizer.step()

        # Сбор статистики по ошибке
        running_loss += loss.item()
        if i % 2000 == 1999: # Вывод каждые 2000 мини-батчей

```

```

print(f'{epoch + 1}, {i + 1:5d}] loss: {running_loss / 2000:.3f}')
loss_history.append(running_loss / 2000)
running_loss = 0.0

print('Обучение завершено')

# --- Шаг 5: Построение графика изменения ошибки ---
plt.figure(figsize=(10, 5))
plt.plot(loss_history)
plt.title('График изменения ошибки обучения')
plt.xlabel('Итерации (x2000)')
plt.ylabel('Ошибка (Loss)')
plt.grid(True)
plt.show()

# Шаг 6: Оценка эффективности на тестовой выборке
correct = 0
total = 0
with torch.no_grad(): # Отключаем вычисление градиентов для оценки
    for data in testloader:
        images, labels = data
        outputs = net(images)
        _, predicted = torch.max(outputs.data, 1)
        total += labels.size(0)
        correct += (predicted == labels).sum().item()

print(f'Точность сети на 10000 тестовых изображений: {100 * correct // total} %')

# --- Шаг 6: Отображение изображения ---
def imshow(img):
    img = img / 2 + 0.5 # денормализация
    npimg = img.numpy()
    plt.imshow(np.transpose(npimg, (1, 2, 0)))
    plt.show()

# Получаем случайные изображения из тестовой выборки
dataiter = iter(testloader)
images, labels = next(dataiter)

# Показываем изображения
print("Изображения для предсказания:")
imshow(torchvision.utils.make_grid(images))

# Выводим истинные метки
print('Истинные метки: ', ''.join(f'{classes[labels[j]]:5s}' for j in range(4)))

# Делаем предсказание
outputs = net(images)
_, predicted = torch.max(outputs, 1)

# Выводим предсказанные метки
print('Предсказания: ', ''.join(f'{classes[predicted[j]]:5s}' for j in range(4)))

# Выбираем одно изображение для индивидуального анализа
image_index = 0
single_image = images[image_index]
true_label = labels[image_index]

```

```

# Подаем одно изображение на вход сети
with torch.no_grad():
    output = net(single_image.unsqueeze(0)) # unsqueeze(0) для добавления batch-размерности
    _, predicted_label = torch.max(output, 1)

print("\n--- Анализ одного изображения ---")
imshow(single_image)
print(f"Истинный класс: {classes[true_label]}")
print(f"Предсказанный класс: {classes[predicted_label.item()]}")

```

Точность сети на 10000 тестовых изображений: 60 %

Изображения для предсказания:




Истинные метки: cat ship ship plane

Предсказания: cat plane truck plane

--- Анализ одного изображения ---

Истинный класс: cat

Предсказанный класс: cat



Вывод: Я научился конструировать нейросетевые классификаторы и выполнять их обучение на известных выборках компьютерного зрения