

Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Обработка изображений в ИС
Лабораторная работа №1
Обучение классификаторов средствами библиотеки PyTorch

Выполнил:
Студент 4-го курса
Группы ИИ-24
Терехов Н. А.
Проверила:
Андренко К. В.

Брест 2025

Цель работы: научиться конструировать нейросетевые классификаторы и выполнять их обучение на известных выборках компьютерного зрения.

Общее задание:

1. Выполнить конструирование своей модели СНС, обучить ее на выборке по заданию (использовать `torchvision.datasets`). Предпочтение отдавать как можно более простым архитектурам, базирующимся на базовых типах слоев (сверточный, полносвязный, подвыборочный, слой нелинейного преобразования). Оценить эффективность обучения на тестовой выборке, построить график изменения ошибки (`matplotlib`);
2. Ознакомьтесь с state-of-the-art результатами для предлагаемых выборок (из материалов в сети Интернет). Сделать выводы о результатах обучения СНС из п. 1;
3. Реализовать визуализацию работы СНС из пункта 1 (выбор и подачу на архитектуру произвольного изображения с выводом результата); 4. Оформить отчет по выполненной работе, загрузить исходный код и отчет в соответствующий репозиторий на github.

19	CIFAR-100	32X32	RMSPprop
----	-----------	-------	----------

Код программы:

```
import os
import argparse
from tqdm import tqdm
from PIL import Image

import torch
import torch.nn as nn
import torch.nn.functional as F
import torch.optim as optim
from torch.utils.data import DataLoader
import torchvision.transforms as T
import torchvision.datasets as datasets
import matplotlib.pyplot as plt

class CIFAR100Classifier(nn.Module):
    def __init__(self, num_categories=100):
        super().__init__()
        self.conv_layers = nn.Sequential(
            nn.Conv2d(3, 32, kernel_size=3, padding=1),
            nn.ReLU(inplace=True),
            nn.MaxPool2d(2), # 16x16
            nn.Conv2d(32, 64, kernel_size=3, padding=1),
            nn.ReLU(inplace=True),
            nn.MaxPool2d(2), # 8x8
```

```

        nn.Conv2d(64, 128, kernel_size=3, padding=1),
        nn.ReLU(inplace=True),
        nn.MaxPool2d(2),    # 4x4
    )

    self.fc_layers = nn.Sequential(
        nn.Flatten(),
        nn.Linear(128 * 4 * 4, 512),
        nn.ReLU(inplace=True),
        nn.Dropout(0.5),
        nn.Linear(512, num_categories)
    )

    def forward(self, x):
        x = self.conv_layers(x)
        x = self.fc_layers(x)
        return x

def run_training_epoch(network, data_loader, loss_fn, opt,
device):
    network.train()
    total_loss = 0.0
    for batch_imgs, batch_labels in tqdm(data_loader,
desc='Training', leave=False):
        batch_imgs, batch_labels = batch_imgs.to(device),
batch_labels.to(device)
        opt.zero_grad()
        predictions = network(batch_imgs)
        loss_value = loss_fn(predictions, batch_labels)
        loss_value.backward()
        opt.step()
        total_loss += loss_value.item() * batch_imgs.size(0)
    return total_loss / len(data_loader.dataset)

def test_model(network, data_loader, loss_fn, device):
    network.eval()
    total_loss = 0.0
    right_predictions = 0
    samples_count = 0
    with torch.no_grad():
        for batch_imgs, batch_labels in data_loader:
            batch_imgs, batch_labels = batch_imgs.to(device),
batch_labels.to(device)
            predictions = network(batch_imgs)
            loss_value = loss_fn(predictions, batch_labels)
            total_loss += loss_value.item() *
batch_imgs.size(0)
            predicted_classes = predictions.argmax(dim=1)
            right_predictions += (predicted_classes ==
batch_labels).sum().item()
            samples_count += batch_imgs.size(0)
    avg_loss = total_loss / len(data_loader.dataset)
    accuracy = right_predictions / samples_count

```

```

        return avg_loss, accuracy
def show_prediction(network, image_path, category_list, device,
image_dim=32):
    network.eval()
    input_image = Image.open(image_path).convert('RGB')
    preprocess = T.Compose([
        T.Resize((image_dim, image_dim)),
        T.ToTensor(),
        T.Normalize(mean=[0.4914, 0.4822, 0.4465], std=[0.2023,
0.1994, 0.2010])
    ])
    input_tensor =
preprocess(input_image).unsqueeze(0).to(device)
    with torch.no_grad():
        output = network(input_tensor)
        probabilities = F.softmax(output,
dim=1).cpu().numpy()[0]
        top5_indices = probabilities.argsort()[-5:][::-1]

    plt.figure(figsize=(4, 4))
    plt.imshow(input_image)
    plt.axis('off')
    plt.title('Лучший результат: {} ({:.2f}%)'.format(
        category_list[top5_indices[0]],
probabilities[top5_indices[0]] * 100))
    plt.show()

    print('\nТоп-5 предсказаний:')
    for idx, class_idx in enumerate(top5_indices, 1):
        print(f"{idx}. {category_list[class_idx]}:
{probabilities[class_idx] * 100:.2f}%")

def execute_training(batch_size=128, num_epochs=15,
learning_rate=0.001, use_gpu=True, output_path='.'):
    compute_device = torch.device('cuda' if
torch.cuda.is_available() and use_gpu else 'cpu')
    print('Используемое устройство:', compute_device)

    # Преобразования данных
    train_transforms = T.Compose([
        T.RandomCrop(32, padding=4),
        T.RandomHorizontalFlip(),
        T.ToTensor(),
        T.Normalize(mean=[0.4914, 0.4822, 0.4465], std=[0.2023,
0.1994, 0.2010])
    ])
    test_transforms = T.Compose([
        T.ToTensor(),
        T.Normalize(mean=[0.4914, 0.4822, 0.4465], std=[0.2023,
0.1994, 0.2010])
    ])

```

```

# Загрузка данных
training_data = datasets.CIFAR100(root='./data',
train=True, download=True, transform=train_transforms)
validation_data = datasets.CIFAR100(root='./data',
train=False, download=True, transform=test_transforms)

training_loader = DataLoader(training_data,
batch_size=batch_size, shuffle=True, num_workers=4,
pin_memory=True)
validation_loader = DataLoader(validation_data,
batch_size=batch_size, shuffle=False, num_workers=4,
pin_memory=True)

category_names = training_data.classes

# Инициализация модели
model =
CIFAR100Classifier(num_categories=len(category_names)).to(compu
te_device)
loss_function = nn.CrossEntropyLoss()
optimizer = optim.RMSprop(model.parameters(),
lr=learning_rate)

# Трекинг метрик
training_loss_history = []
validation_loss_history = []
validation_accuracy_history = []

best_accuracy = 0.0
os.makedirs(output_path, exist_ok=True)

# Цикл обучения
for epoch in range(1, num_epochs + 1):
    print(f'\nЭпоха {epoch}/{num_epochs}')

    # Обучение
    epoch_train_loss = run_training_epoch(model,
training_loader, loss_function, optimizer, compute_device)

    # Валидация
    epoch_val_loss, epoch_val_accuracy = test_model(model,
validation_loader, loss_function, compute_device)

    # Сохранение метрик
    training_loss_history.append(epoch_train_loss)
    validation_loss_history.append(epoch_val_loss)
    validation_accuracy_history.append(epoch_val_accuracy)

    print(
        f'Потери на обучении: {epoch_train_loss:.4f} |
Потери на валидации: {epoch_val_loss:.4f} | Точность:
{epoch_val_accuracy * 100:.2f}%')

```

```

        # Сохранение лучшей модели
        if epoch_val_accuracy > best_accuracy:
            best_accuracy = epoch_val_accuracy
            model_save_path = os.path.join(output_path,
'cifar100_rmsprop_model.pth')
            torch.save(model.state_dict(), model_save_path)
            print(f'Новая лучшая модель сохранена! Точность:
{best_accuracy * 100:.2f}%')

    # Визуализация результатов
    plt.figure(figsize=(12, 4))

    plt.subplot(1, 2, 1)
    plt.plot(range(1, num_epochs + 1), training_loss_history,
label='Обучение')
    plt.plot(range(1, num_epochs + 1), validation_loss_history,
label='Валидация')
    plt.xlabel('Эпоха')
    plt.ylabel('Потери')
    plt.legend()
    plt.grid(True)
    plt.title('Динамика потерь')

    plt.subplot(1, 2, 2)
    plt.plot(range(1, num_epochs + 1),
validation_accuracy_history, label='Точность', color='green')
    plt.xlabel('Эпоха')
    plt.ylabel('Точность')
    plt.legend()
    plt.grid(True)
    plt.title('Точность на валидации')

    plt.tight_layout()
    plot_file = os.path.join(output_path,
'training_results.png')
    plt.savefig(plot_file)
    print('\nГрафики сохранены в', plot_file)

    # Финальная оценка
    final_loss, final_accuracy = test_model(model,
validation_loader, loss_function, compute_device)
    print(f'\nФинальная точность: {final_accuracy * 100:.2f}%')
    print(f'Лучшая точность: {best_accuracy * 100:.2f}%')
    print(f'Модель сохранена: {model_save_path}')

    # Тест на примере изображения
    sample_image_path = os.path.join('.', 'sample_image.jpg')
    if os.path.exists(sample_image_path):
        try:
            print(f'\nТестирование на изображении:
{sample_image_path}')
            show_prediction(model, sample_image_path,
category_names, compute_device)

```

```

        except Exception as e:
            print('Ошибка при обработке изображения:', e)
    else:
        print(f"\nФайл '{sample_image_path}' не найден.")
        print("Для тестирования поместите изображение в текущую
директорию и назовите 'sample_image.jpg'")

if __name__ == '__main__':
    arg_parser = argparse.ArgumentParser(description='Обучение
классификатора CIFAR-100 с RMSprop')
    arg_parser.add_argument('--batch-size', type=int,
default=128, help='Размер батча')
    arg_parser.add_argument('--epochs', type=int, default=15,
help='Количество эпох')
    arg_parser.add_argument('--lr', type=float, default=0.001,
help='Скорость обучения для RMSprop')
    arg_parser.add_argument('--no-cuda', action='store_true',
help='Не использовать GPU')
    arg_parser.add_argument('--save-dir', type=str,
default='.', help='Директория для сохранения')
    arguments = arg_parser.parse_args()

    execute_training(
        batch_size=arguments.batch_size,
        num_epochs=arguments.epochs,
        learning_rate=arguments.lr,
        use_gpu=not arguments.no_cuda,
        output_path=arguments.save_dir
    )

```

Результат работы программы:

Эпоха 14/15

Потери на обучении: 2.3018 | Потери на валидации: 2.0384 | Точность: 45.96%

Новая лучшая модель сохранена! Точность: 45.96%

Эпоха 15/15


Потери на обучении: 2.2678 | Потери на валидации: 2.0862 | Точность: 45.41%

Графики сохранены в ./training_results.png

Финальная точность: 45.41%

Лучшая точность: 45.96%

Модель сохранена: ./cifar100_rmsprop_model.pth



Тестирование на изображении:

Топ-5 предсказаний:

1. whale: 39.00%
2. dolphin: 37.51%
3. shark: 9.56%
4. turtle: 5.41%
5. seal: 5.01%

Figure 2

Лучший результат: whale (39.00%)



Вывод: научился конструировать нейросетевые классификаторы и выполнять их обучение на известных выборках компьютерного зрения.